

第一章：机器学习

概念

机器学习是一种通过先验信息来提升模型能力的方式

组成：数据、模型和性能度量准则

机器学习术语

分类：使用计算机学习出的模型进行预测得到的是离散值

二分类：只涉及到两个类别的分类任务，一个是正类，一个是负类

多分类：涉及到多个类别的分类任务

回归：使用计算机学习出的模型得到的是连续值

聚类：对无标签样本的相似度进行度量，挖掘特征、结构、内在性质，使类内相似度大、类间相似度小

分类和回归的区别

1.输出不同

分类问题输出的是物体所属的类别，回归问题输出的是物体的值；分类问题输出的值是定性的，回归问题输出的值是定量的

2.目的不同

分类的目的是为了寻找决策边界，回归的目的是为了找到最优拟合


3.结果不同

分类的结果没有逼近，对就是对，错就是错；回归是对真实值的一种逼近预测

训练误差或经验风险：指模型在训练样本集上的整体误差

测试误差：模型在测试样本集上的整体误差

正则化



过拟合：同时拟合训练样本的共性特征和个性特征

欠拟合：未能充分拟合训练样本共性特征造成模型泛化误差较大而导致模型泛化能力较弱

过拟合的解决措施：获取更多训练数据(减少噪声影响)；降维（丢弃一些无用的特征）；正则化（减少参数的大小）；集成学习方法：多个模型集成一起，降低单一模型的风险

欠拟合的处理：添加新特征（相关性不强，容易出现欠拟合）；增加模型复杂度（简单的模型学习能力差）；减少正则化系数（因为正则化是用来防止过拟合的）

机器学习的分类

监督学习、半监督学习和无监督学习

监督学习：在建立预测模型的过程中将预测结果与训练数据的实际结果进行比较，不断的调整预测模型，直到模型的预测结果达到一个预期的准确率

典型例子：分类和回归任务、决策树、贝叶斯模型、支持向量机、深度学习

无监督学习：数据并不被特别标识，计算机自行学习分析数据内部的规律、特征等，进而得出一定的结果

典型例子：聚类算法

半监督学习：介于两者之间，输入数据部分被标识，部分没有被标识，没标识的数据量远远大于有标识的数据量

基于与环境的交互进行学习

生成模型和判别模型(是否可用于生成新的数据)

生成模型：联合概率分布 $P(X,Y)$ ，计算 X 与不同标记之间的联合分布概率，选择其中最大的概率对应的标签作为预测输出。比如朴素贝叶斯生成器、高斯混合模型、隐马尔可夫模型、生成对抗网络等

判别模型：条件概率分布 $P(X|Y)$ ，即后验概率分布。比如逻辑回归、决策树、支持向量机、神经网络、K-近邻算法

机器学习的一般流程

1.获取数据

2.数据处理

3.特征工程

4.机器学习（模型训练）

5.模型评估

特征工程：把原始数据转化为模型的训练数据的过程，目的是为了获取更好的训练数据特征，一般包括特征构建、特征提取、特征选择三部分