

第七章 集成学习

算法概述

用多种学习方法的组合来获取比原方法更优的结果。基本思想：先通过一定的规则生成一定数量的基学习器，再采用某种集成策略将这些基学习器的预测结果组合起来，从而形成最终的结论

- 个体的生成方法
- 基学习器(个体学习器)
 - 基学习器可以是同质的“弱学习器”，也可以是异质的“弱学习器”
- 三个部分组成
 - 结论的合(集)成方法
 - 分类任务中，集成的输出通常由各个体学习器的输出投票产生。通常采用绝对多数投票法或相对多数投票法
 - 当用于回归估计时，集成的输出通常由各学习器的输出通过简单平均或加权平均产生
 - 同质的学习器按照个体学习器之间是否存在依赖关系又可以分为两类
 - 存在强依赖关系，对之间训练中错误标记的样本赋以较高的权重值，以此提高整体的预测效果。代表算法：Boosting算法
 - 不存在强依赖关系，可以并行生成这些个体学习器，并行方法的原理是利用基学习器之间的独立性，通过平均可以显著降低错误率。代表算法：Bagging和随机森林

随机森林

- 算法原理
 - (1) 抽样产生每颗决策树的训练数据集。训练子集中的样本存在一定的重复，每一棵树的输入样本都不是全部的样本，使森林中的决策树不至于产生局部最优解
 - (2) 构建n棵决策树(基学习器)。在进行节点分裂时，随机选择m个特征($m \ll M$)参与比较，，减少了决策树之间的相关性，提升了决策树的分类精度，从而达到结点的随机性
 - (3) 生成随机森林。使用第(2)步n棵决策树对测试样本进行分类，随机森林将每颗子树的结果汇总，以简单多数的原则决定该样本的类别

提升法(boosting)

Boosting是一种可将弱学习器提升为强学习器的算法。这种算法从初始训练集训练出一个基学习器，再根据基学习器的表现对训练样本分布进行调整，使得先前基学习器做错的训练样本在后续受到更多关注，然后基于调整后的样本分布来训练下一个基学习器。如此重复进行，直至基学习器数目达到事先指定的值T，最终将这T个基学习器进行加权结合。

boosting算法的个体分类器可以是不同类的分类器

- 原理
 - 1) 训练阶段。给定一个训练集X，划分成3个子集(X_1, X_2, X_3)，首先使用 X_1 训练基分类器 d_1 ，接着提取 X_2 并将它作为 d_1 的输入，将 d_1 错误分类的所有样本以及 X_2 中被 d_1 正确分类的部分样本一起作为 d_2 的训练集。最后提取 X_3 ，并将它输入给 d_1 和 d_2 ，其中用 d_1 和 d_2 输出不一致的样本作为 d_3 的训练集。
 - 2) 检验阶段。给定一个样本，首先将其提供给 d_1 和 d_2 ，如果二者输出一致，这就是输出结果，否则以 d_3 的输出作为最终输出结果
- 缺点：需要一个非常大的训练样本集，将样本集一分为三(很多场合不太现实)


- 改进
 - 提升法——AdaBoost
 - 工作流程：
首先，训练集用初始权重训练出一个弱学习器1，根据弱学习的学习误差率表现来更新训练样本的权重，使得之前弱学习器1学习误差率高的训练样本点的权重变高，使得这些误差率高的点在后面的弱学习器2中得到更多的重视。
然后，基于调整权重后的训练集来训练弱学习器2，如此重复进行，直到训练到指定的弱学习器数量。
最后，将这些弱学习器通过集合策略进行整合，得到最终的强学习器
 - 提升法——GBDT提升树
 - 算法原理：
梯度提升——用于回归和分类的方法，生成一个由弱分类器（通常是决策树）组成的强学习器。在回归中，称为梯度提升回归树(GBRT)。在分类中，称为梯度提升决策树(GBDT)。

偏差与方差


偏差是预测结果与真实值之间的差异，排除噪声的影响，偏差更多针对是某个模型输出的样本误差，偏差是模型无法准确表达数据关系导致

方差指多个(次)模型输出的结果之间的离散差异(即不同模型或同一模型不同时间的输出结果方差较大)，方差是由训练集的数据不够导致的，即数据量不够、数据量训练过度导致模型复杂或样本质量不行

- 偏差
 - 所有可能的训练数据集训练出的所有模型的输出的平均值与真实模型的输出值之间的差异，即刻画了学习算法本身的拟合能力
- 方差
 - 不同的训练数据集训练出的模型输出值之间的差异，即刻画了数据扰动所造成的影响
- 噪声
 - 学习算法无法解决的的问题，数据的质量决定了学习的上限，即刻画了学习问题本身的难度



偏差-方差分解 说明：泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度所共同决定的。给定学习任务，为了取得好的泛化性能，则需使偏差较小，即能够充分拟合数据，并且使方差较小，即使得数据扰动产生的影响小。



偏差 - 方差窘境 说明：实际在选择模型时，随着模型复杂度的增加，模型的偏差越来越小，而方差会越来越大。如图所示，存在某一时刻，模型的方差和偏差之和最小，此时模型性能在误差及泛化能力方面达到最优。

偏差、方差与过拟合、欠拟合的关系

- 一般来说，简单的模型会有一个较大的偏差和较小的方差，复杂的模型偏差较小方差较大
- 欠拟合：模型不能适配训练样本，有一个很大的偏差
- 过拟合：模型很好的适配训练样本，但在测试集上表现很糟，有一个很大的方差
- 解决偏差：避免欠拟合
 - 1.寻找更好的特征——具有代表性
 - 2.更多的特征——增大输入向量的维度，增加模型复杂度
- 解决方差：避免过拟合
 - 1.增大数据集——使用更多的数据，减少数据扰动所造成的影响
 - 2.减少数据特征——减少数据维度，减少模型复杂度
 - 3.正则化方法
 - 4.交叉验证法

偏差、方差与bagging、boosting的关系

- Bagging算法是对训练样本采样，产生出若干不同的子集，再从每个数据集中训练出一个分类器，取这些分类器的平均，所以是降低模型的方差
- Boosting是迭代算法，每一次迭代都根据上一次迭代的预测结果对样本进行权重调整，所以随着迭代不断进行，误差会越来越小，模型的偏差会不断降低