

模式识别、数据挖掘、自然语言处理、辅助智能决策等。其中针对很多领域核心问题的分类问题——中文分词、机器翻译、故障诊断、疾病诊断


贝叶斯网络的应用

高斯朴素贝叶斯分类器：连续值

多项式贝叶斯分类器：离散值

伯努利贝叶斯分类器：二值(T/F)

算法应用



第五章 朴素贝叶斯分类器

算法概述

朴素贝叶斯——基于概率论的分类算法，基于贝叶斯定理与特征属性独立假设属于监督学习的生成模型。即对已知类别，假设说有特征属性相互独立。

$$P(A|B \times C) = \frac{P(B|A) \times P(C|A) \times P(A)}{P(B) \times P(C)}$$

朴素贝叶斯分类是基于贝叶斯定理和特征条件独立假设的分类算法

特点：

1. 朴素贝叶斯对缺失数据不太敏感，常用于文本分类识别、欺诈检测、垃圾邮件过滤、拼写检查等领域
2. 朴素贝叶斯有稳定的分类效率，在大量样本下会有较好的表现，对小规模的数据仍然有效，能处理多分类任务
3. 朴素贝叶斯适合增量式训练，即可实时对新增样本进行训练

贝叶斯理论

问题：已知条件(似然)概率P(B|A)的情况下，如何求后验概率P(A|B)?

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- 先验概率 $P(A)$ ：在观测到数据之前，人们对参数的了解。
- 似然概率 $P(B|A)$ ：如何在实验中引入观测数据，反映的是在给定参数下得到观测数据的可信度。
- 后验概率 $P(A|B)$ ：是贝叶斯分析的结果，反映的是在给定数据和模型的条件下，人们对问题的全部认知。需要注意的是，后验指模型中参数的概率分布而不是某个值，该分布正比于先验乘以似然。
- 证据 $P(B)$ ：也叫归一化系数，证据是在模型的参数取遍所有可能值的条件下得到指定观测值的概率的归一。

假设一个班级有90%男生和10%女生，女生穿裙子的人数和穿裙子的人的概率，所有女生都穿裙子，一个人在操场随机看到了一分钟穿裙子的女生，那么这个女生是女生的概率是多少？
使用贝叶斯理论：事件A是看到女生，事件B是看到一个穿裙子的女生，求事件A|B。
a. $P(A)$ 是女生在班级的概率，看到女生是0.1。
b. $P(B|A)$ 是女生穿裙子的概率，假设女生都穿裙子，为0.9。
c. $P(B|A)$ 是女生穿裙子的概率，为0.9。
d. $P(B|A)$ 是女生穿裙子的概率，为0.9。
e. $P(B)$ 是看到女生的概率，学生穿裙子的概率： $P(B) = P(B|A)P(A) + P(B|\bar{A})P(\bar{A}) = 0.1 \times 0.9 + 0.9 \times 0.9 = 0.81$
根据贝叶斯定理，求A|B的概率：
$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{0.9 \times 0.1}{0.81} = 0.1111$$

可见在证据中求后验概率

对数技巧

很多概率连乘，很容易造成浮点计算下溢出
$$\underset{k \in \{1, \dots, K\}}{\operatorname{argmax}} P(C_k) \prod_{i=1}^n P(X_i|C_k)$$

取对数把乘法转化成加法
$$\log(P(C_k)) + \sum_{i=1}^n \log(P(X_i|C_k))$$

案例：预测打网球、预测西瓜好坏（参考PPT）

问题：有类预测没特征的特征会导致以假为真
解决之道：在计算条件概率的分子和分母上各加1
$$P(C|X) = \frac{0}{P(X_1|C)} \rightarrow P(X_2|C) + P(C)$$

$$P(X_1|C) = \frac{1}{\operatorname{Count}(C) + n}$$

$$P(X_2|C) = \frac{\operatorname{Count}(X_2 \& C) + 1}{\operatorname{Count}(C) + m}$$

拉普拉斯平滑技术：

$$P(C|X) = P(X|C) \times P(C)$$

给定特征和属性 X ，计算其属于每个类别 C 的概率
按照最大后验概率原则，把 X 分入概率最大的类别
$$\underset{k \in \{1, \dots, K\}}{\operatorname{argmax}} P(C_k) \prod_{i=1}^n P(X_i|C_k)$$

训练朴素贝叶斯：朴素假设

算法流程

算法步骤

➢ 对于确定所有待分类数据，确定其特征属性 x_i ，获取训练样本集合 y_i 。
D = $\{(x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}, y_1), (x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)}, y_2), \dots, (x_1^{(m)}, x_2^{(m)}, \dots, x_n^{(m)}, y_m)\}$
其中：m 表示有 m 个样本，n 表示有 n 个特征， y_i 表示训练样本集合，取值 $\{C_1, C_2, \dots, C_K\}$ 。
➢ 计算各类别的先验概率 $P(Y = C_k)$
针对训练样本，我们可以利用极大似然估计计算先验概率。但为了弥补极大似然估计中可能出现概率值为 0 的情况，也就是某个事件出现的次数为 0，我们使用贝叶斯估计计算先验概率：
$$P(Y = C_k) = \frac{\sum_{i=1}^m I(y_i = C_k) + 1}{m + K}$$

其中： $\sum_{i=1}^m I(y_i = C_k)$ 计算的是样本类别为 C_k 的总数，K 为类别的个数。先验概率计算的是类别 C_k 在训练样本集中的概率。

➢ 计算各类别下各特征属性 x_{ij} 的条件概率
① 如果 x_{ij} 是离散值，我们可以假设 x_{ij} 符合多项式分布，这样得到的条件概率是在样本类别 C_k 中，特征 x_{ij} 出现的概率，即
$$P(x_{ij} = x_j | Y = C_k) = \frac{\sum_{i=1}^m I(x_{ij} = x_j, y_i = C_k)}{\sum_{i=1}^m I(y_i = C_k)}$$

其中： $\sum_{i=1}^m I(x_{ij} = x_j, y_i = C_k)$ 为样本类别 C_k 中，特征属性 x_{ij} 出现的概率。
② 如果 x_{ij} 是连续二项离散值，即各个特征出现概率很低，我们可以假设 x_{ij} 符合伯努利分布，即假设 x_{ij} 出现记为 1，不出现在记为 0。我们只关注 x_{ij} 出现的次数，这样得到的条件概率是在样本类别 C_k 中， x_{ij} 出现的概率。此时有
$$P(x_{ij} = x_j | Y = C_k) = P(x_{ij} = 1 | Y = C_k) x_j + (1 - P(x_{ij} = 1 | Y = C_k))(1 - x_j)$$

其中： $x_j \in \{0, 1\}$ 。
③ 如果 x_{ij} 是连续值，我们通常取 x_{ij} 的先验概率为正态分布，即在样本类别 C_k 中， x_{ij} 的符合正态分布，这样得到的条件概率分布是
$$P(x_{ij} = x_j | Y = C_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x_{ij} - \mu_k)^2}{2\sigma_k^2}\right)$$

其中： μ_k 和 σ_k^2 是正态分布的期望和方差，可以通过极大似然估计求得。 μ_k 为在样本类别 C_k 中，所有 x_{ij} 的平均值。 σ_k^2 为在样本类别 C_k 中，所有 x_{ij} 的方差。对于一个连续值的样本，代入正态分布的公式，就可以求得概率分布。

➢ 计算各类别的后验概率 $P(Y = C_k | X = x)$
由于假设各特征属性是条件独立的，则根据贝叶斯定理，各类别的后验概率有如下推导：
$$P(Y = C_k | X = x) = \frac{P(X_{ij} = x_j | Y = C_k) P(Y = C_k)}{P(X = x)}$$

由于对于所有的类别计算后验概率时，分母是一样的，因此我们的预测公式可以简化为：
$$C_{\text{max}} = \underset{k}{\operatorname{argmax}} P(X_{ij} = x_j | Y = C_k) P(Y = C_k)$$

我们利用朴素贝叶斯的独立性假设，就可以得到通常意义上的朴素贝叶斯推断公式：
$$C_{\text{max}} = \underset{k}{\operatorname{argmax}} P(Y = C_k) \prod_{i=1}^n P(X_i = x_i | Y = C_k)$$

具体看题目会算就行，一般考试也只考离散值