

第三章 KNN

算法概述

给定测试样本，基于特定的某种距离度量方式找到与训练集中最接近的k个样本，然后基于这k个样本的类别进行预测

基本要素：
距离度量、K值的选择和分类决策规则

关键问题

距离的度量，一般采用欧氏距离

如何快速地进行k个近邻的检索

k值的选取（投票法）


k值大小的影响

- 较小的k值
 - 用较少训练实例预测，非常相似的实例才起作用，学习的近似误差会减小
 - 预测结果与少量实例有关，对近邻数据非常敏感，学习的估计误差会增大
 - 噪声敏感
 - k值的减小意味着模型变复杂，容易过拟合
- 较大的k值
 - 用较多训练实例进行预测，学习的估计误差会减小
 - 与输入距离较远的实例也会起作用，学习的近似误差会增大
 - k值的增大意味着模型变简单，容易欠拟合

近似误差：模型预测结果与实际结果之间的误差，即模型在训练数据上的预测误差。近似误差减小时，易出现过拟合

估计误差：模型参数与实际参数之间的差异，即模型在新数据上的预测误差。估计误差减小时，模型的泛化能力强

算法流程



算法的改进与优化

优点

简单、易理解和实现
无需估计参数、无需训练
精度高、对异常值不敏感
特别适合于多分类问题
无数据输入假定

缺点

当样本不平衡时，效果较差
计算复杂度高
空间复杂度高
可理解性差，无法给出像决策树那样的规则

优化

引入邻域权值，即对距离测试样本更近的邻居设置更大的权值，衡量权值累积以及训练样本集中各种分类的样本数目，来对算法中的K值进行调整，进而达到更合理或者平滑的分类效果

特征降维与模式融合，KNN算法的主要缺点是当训练样本数量很大时将导致很高的计算开销。为了对KNN的分类效率进行优化，可以在数据预处理阶段利用一些降维算法或者使用特征融合算法，对KNN训练样本集的维度进行简化，排除对分类结果影响较小的属性。通过优化训练样本集的分类，提高得出待分类样本类别的效率。该改进经常在类域的样本容量比较大时使用

优化与改进

快速检索

一个朴素的思想：
(1)计算样本x与训练集中所有样本的距离。
(2)将这些点依据距离从小到大进行排序选择前k个
另一种方法：
为训练样本实现建立索引，以此减少计算的规模。kd树是一种典型的存储k维空间数据的数据结构

改进

分组快速搜索近邻法

基本思想：
1.将样本集按近邻关系分解成组
2.以每组的质心作为代表点与未知样本计算距离
3.选出距离最近的一个或若干个组
4.在组的范围内应用一般的KNN算法

数据标准化

离差标准化数据

特点：
数据整体分布不会随离差标准化而发生改变
数据和最小值相等的时候，离差标准化数据为0
数据极差过大，离差标准化数据之间的差值变得非常小
缺点：极差大，标准化值接近于0，且相互之间差别不大；若遇到超过区间内的值，需要重新确定min和max

标准差标准化数据

标准差标准化数据与离差标准化数据类似，是指使用最广泛的数据标准化方法。经过此方法处理的数据均值变为0，标准差为1。
$$x' = \frac{x - \bar{x}}{s}$$

其中x为原始数据中的值，x为原始数据的均值，s为原始数据的标准差。标准差标准化的数据值不会出现于(0,1)，并自身存在缺点。同时也不需发现，标准差和离差标准化类似，是一种只改变数据分布范围。

不会改变数据分布情况

小数定标标准化数据

通过乘以数据的小数位数，将数据映射到区间(0,1)之间，映射的小数位数取决于数据绝对值的最大值。转化公式如下：
$$x' = \frac{x}{10^d}$$

总结：
离差标准化方法简单，便于理解，标准化后的数据限定在[0,1]区间内
标准差标准化收到数据分布的影响小
小数定标标准化适用范围广，受到数据分布的影响小，适用程度适中