

第二章

线性回归

线性回归研究的是自变量和因变量之间的线性关系，求解线性回归的基本方法是最小二乘法，最小二乘法是一个不带条件的最优化问题，优化目标是让整个样本集合上的预测值与真实值之间的欧式距离之和最小

一元线性回归

包含一个自变量和一个因变量，基于均方误差最小化来进行模型求解的方法称为“最小二乘法”

- 给定空间中的一组样本点 $D(X_1, y_1), \dots, (X_N, y)$ ，目标函数为

$$\min J(\alpha, b) = \min \sum_{i=1}^N (y_i - f(x_i))^2 = \min \sum_{i=1}^N (y_i - \alpha x_i - b)^2$$
- 令目标函数对 α 和 b 的偏导数为0

$$\frac{\partial J(\alpha, b)}{\partial \alpha} = \sum_{i=1}^N 2\alpha x_i - \sum_{i=1}^N 2y_i (x_i - y_i) = 2\alpha b$$
- 则可得到 α 和 b 的估计值

$$\alpha = \frac{\sum_{i=1}^N x_i y_i - \alpha \sum_{i=1}^N x_i y_i}{\sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2} = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\bar{x}^2 - \bar{x}^2}$$

$$b = \frac{1}{n} \left(\sum_{i=1}^N y_i - \alpha \sum_{i=1}^N x_i \right) = \bar{y} - \alpha \bar{x}$$

多元线性回归

- 可以将 $\bar{y}$ 同样看作权重，即

$$\bar{w} = (a_0, a_1, \dots, a_n, b)$$

$$\bar{f}_n = (x^0, x^1, \dots, x^n, 1)$$
- 此时 $\gamma = \gamma(x) = \bar{w}^T \bar{f}_n$ ，优化目标为 $\min_{\bar{w}} J(\bar{w}) = \frac{1}{2} \bar{X}^T \bar{X} \bar{w} - \bar{X}^T \bar{y}$ 其中 $\bar{X}$ 为样本带偏的推广矩阵， $\bar{y}$ 为对应的标签向量

$$\bar{X} = \begin{bmatrix} x_1^0 & x_1^1 & \dots & x_1^n & 1 \\ x_2^0 & x_2^1 & \dots & x_2^n & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_n^0 & x_n^1 & \dots & x_n^n & 1 \end{bmatrix}$$

$$\bar{y} = (y_1, y_2, \dots, y_n)^T$$


- 求解优化目标可得 $\bar{w} = (\bar{X}^T \bar{X})^{-1} \bar{X}^T \bar{y}$
- 当 $\bar{X}^T \bar{X}$ 可逆时，线性回归模型存在唯一解。

最小二乘法的局限性

第一，最小二乘法需要计算 $X^T X$ 的逆矩阵，有可能它的逆矩阵不存在，这样就没有办法直接用最小二乘法了

第二，当样本特征 N 是一个非常大的数时，计算 $X^T X$ 的逆矩阵耗时大


第三，拟合函数需要是线性的



求解流程


一步步完成迭代，沿着负梯度方向迭代，更新后的 θ 使 $J(\theta)$ 值更小

一步步完成迭代，沿着负梯度方向迭代，更新后的 θ 使 $J(\theta)$ 值更小



求极值的主要问题

求极值的主要问题



- 1.梯度下降的超参数（步长）需要人为设置，但往往不好设置
- 2.如果目标函数有多个极小值点（很多低谷），开始位置不理想很容易卡在一个局部最小值

批量梯度下降，（容易得到最优解，但是由于每次考虑所有样本，速度很慢）

随机梯度下降，（每次找一个样本，迭代速度快，但每一次不一定朝着收敛的方向）

小批量梯度下降法，（每次更新选择一小部分数据来算，实用）

逻辑回归

将线性回归模型输出的连续值进行离散化

Logistic 函数 $P(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$

对数几率 $\log \left[\frac{P(x)}{1-P(x)} \right] = \beta_0 + \beta_1 x$

对数几率函数是任意阶可导的凸函数，有很好的数学性质

逻辑回归的基本原理，求解过程分为以下三步：

1. 找一个合适的预测分类函数
2. 构造一个损失函数，该函数表示预测输出(h)与训练数据类别(y)之间的偏差
3. 找到 $J(\theta)$ 函数的最小值，因为值越小表示越精确

直接对分类可行性建模，无需事先假设数据分布

不是仅预测出类别，还可得到对近似概率的预测

对数几率函数是任意阶可导的凸函数，有很好的数学性质

优点

预测值 →	1	0
1	TP	FN (假阴率: 并不是负样本)
0	FP (假阳率: 并不是正样本)	TN

混淆矩阵

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$


准确率：预测正确的结果占总样本的百分比，但在样本不平衡的情况下，并不能作为很好的指标来衡量结果

$$\text{precision} = \frac{TP}{TP + FP}$$

精确率(查准率): 所有被预测为正的样本中实际为正的样本的概率——推荐系统

$$\text{recall} = \frac{TP}{TP + FN}$$

召回率(查全率): 在**实际为正**的样本中被预测为**正样本**的概率——**网贷违约**




纵坐标为精确率，横坐标为召回率，置信度为[0,1]。
一般来说，置信度阈值较低时，大量样本被预测为正例，所以召回率较高，精确率较低；置信度阈值较高时，大量样本被预测为负例，所以召回率较低，精确率较高

准确率与召回率

评价指标

对分类能力形象的表征, 横轴: 假阳率(FPR), 纵轴: 真阳率(TPR)



(0, 0): 假阳率和真阳率都为0, 即分类器全部预测成负样本。
(0, 1): 假阳率为0, 真阳率为1, 全部完美预测正确。即FN、FP都为0
(1, 0): 假阳率为1, 真阳率为0, 全部完美预测错误。即TN、TP都为0
(1, 1): 假阳率和真阳率都为1, 即分类器全部预测成正样本
当TPR = FPR为一条斜对角线时, 表示预测为正样本的结果一半是对的, 一半是错的, 即为随机分类器的预测效果。ROC曲线在斜对角线以下, 表示该分类器效果差于随机分类器; 反之, 效果好于随机分类器。当然, 我们希望ROC曲线尽量位于斜对角线以上, 也就是向左上角(0, 1)凸。

